

BAB 1: PROBLEM DISCOVERY & PENDAHULUAN

1.1 Latar Belakang Masalah

Dalam pelaksanaan program pelatihan intensif Coding Camp, platform komunikasi dan forum peserta dibanjiri oleh volume pertanyaan yang sangat tinggi. Berdasarkan hasil analisis terhadap data forum, ditemukan masalah utama yaitu sebagian besar pertanyaan dari peserta bersifat prosedural dan administratif (seperti masalah absensi, jadwal *Instructor-Led Training* / ILT, dan mekanisme capstone), alih-alih pertanyaan teknis (*technical blocking*).

Jika masalah ini dibiarkan, fasilitator dan mentor akan terus menghabiskan waktu mereka untuk menjawab pertanyaan repetitif secara manual. Hal ini berdampak negatif pada efisiensi operasional dan memperlambat respons penanganan bagi peserta yang benar-benar mengalami kendala teknis krusial pada kode mereka.

1.2 Solusi Utama

Dikembangkan Coding Camp Copilot, sebuah asisten kecerdasan buatan (AI) berbasis *Natural Language Processing* (NLP). Solusi ini dirancang untuk secara otomatis mengklasifikasikan dan merutekan pertanyaan peserta ke dalam tiga *Path* utama yaitu AI Engineer, Data Scientist, dan Full Stack Development.

Nilai inovasinya terletak pada otomasi alokasi tiket pertanyaan. Dengan Copilot, pertanyaan administratif dapat langsung difilter atau diarahkan ke FAQ yang tepat secara *real-time*, membebaskan beban kognitif mentor dan memangkas waktu tunggu peserta.

1.3 Pertanyaan Bisnis (Business Questions)

Definisikan pertanyaan bisnis yang spesifik, terukur, dan berorientasi pada tindakan yang ingin dijawab melalui analisis data ini.

1. Kategori path mana yang memiliki volume pertanyaan terbanyak dalam dataset, dan berapa persentase dominasinya?
2. Apa 10 kata kunci atau topik yang paling sering muncul dalam pertanyaan peserta secara keseluruhan, dan apakah topik tersebut

berbeda antar kategori jalur?

BAB 2: DATA WRANGLING & PERSIAPAN DATA

2.1 Data Gathering (Pengumpulan Data)

Dataset yang digunakan dalam proyek ini bersumber dari data internal atau histori percakapan forum dan *chat* program Coding Camp. Data diekspor dan dikumpulkan dalam format CSV yang memuat rekam jejak pertanyaan peserta beserta jawaban dari fasilitator.

2.2 Data Assessing (Penilaian Kualitas Data)

Pemeriksaan awal terhadap struktur data mentah menghasilkan temuan berikut:

- Dimensi Data: Terdiri dari 365 baris dan 5 kolom
- Missing Values: Kolom **ID** memiliki nilai kosong (Null) sebesar 51.5%.
- Inkonsistensi Data: Terdapat 15 variasi penulisan yang berantakan pada kolom Path.
- Noise pada Teks: Kolom Pertanyaan mengandung banyak URL, tanda baca, huruf kapital yang tidak seragam, dan karakter non-alfanumerik.

2.3 Data Cleaning (Pembersihan Data)

Untuk mengatasi masalah kualitas data, dilakukan langkah-langkah pembersihan sistematis menggunakan pustaka Pandas, Regex, dan Sastrawi:

1. Kolom ID dihapus karena tidak memiliki nilai prediktif dan mayoritas kosong. Baris pertanyaan yang sangat pendek dihapus.
2. Mengubah 15 variasi nama pada kolom Path menjadi tiga kategori standar yang bersih yaitu *AI Engineer*, *Data Scientist*, dan *Full Stack Development*.
3. Mengubah seluruh teks menjadi huruf kecil (*lowercasing*), menghapus URL/tanda baca, menghapus kata hubung tak bermakna (*Stopword Removal*), dan mengembalikan kata ke bentuk dasar (*Stemming* menggunakan pustaka Sastrawi).

2.4 Data Dictionary (Kamus Data)

Sajikan informasi metadata mengenai dataset yang telah bersih menggunakan tabel di bawah ini:

Nama Fitur / Kolom	Tipe Data	Deskripsi Keterangan
Nama	String	Nama atau <i>username</i> cohort yang mengajukan pertanyaan.
Path	String	Jalur pembelajaran peserta (AI Engineer, Data Scientist, Full Stack).
Pertanyaan	String	Teks asli pertanyaan peserta di forum.
Jawaban	String	Teks jawaban yang diberikan oleh fasilitator.
Kategori_Label	Integer	Representasi numerik dari <i>Path</i> (0, 1, atau 2) sebagai target model.
Pertanyaan_Bersih	String	Teks pertanyaan yang telah melewati proses <i>stemming</i> dan <i>cleaning</i> .

BAB 3: EXPLORATORY DATA ANALYSIS (EDA) & EXPLANATORY ANALYSIS

3.1 Exploratory Data Analysis (EDA)

Analisis univariat pada distribusi *Path* menunjukkan adanya ketidakseimbangan kelas ringan, di mana volume pertanyaan tidak tersebar rata. Analisis frekuensi kata menemukan bahwa kata-kata seperti *ilt*, *sesi*,

kelas, *absent*, dan *email* mendominasi keseluruhan kumpulan data. Pola menarik ditemukan: peserta AI Engineer dan Data Scientist cenderung bertanya seputar operasional sesi (ILT), sedangkan Full Stack Development lebih fokus pada teknis koordinasi dokumen dan proyek.

3.2 Explanatory Analysis & Visualisasi Data

Visualisasi yang disajikan di dalam *dashboard* memberikan jawaban langsung atas pertanyaan bisnis. Meskipun data tersebar di tiga path, grafik menunjukkan distribusi volume pertanyaan tertinggi mengelompok secara spesifik pada jalur tertentu, dengan selisih yang mencolok. Hal ini membuktikan bahwa dokumentasi FAQ atau materi orientasi awal (*Playbook*) belum sepenuhnya dipahami oleh peserta secara merata. *Path* dengan volume pertanyaan terbanyak membutuhkan penambahan panduan administratif yang lebih komprehensif.

BAB 4: FEATURE ENGINEERING & EKSPERIMEN A/B TESTING

4.1 Feature Engineering

Karena model *Machine Learning* tidak dapat membaca teks secara langsung, dilakukan dua metode rekayasa fitur untuk mengonversi kolom *Pertanyaan_Bersih* menjadi matriks numerik:

1. **Pendekatan Statistik (TF-IDF):** Menggunakan *TfidfVectorizer* untuk mengekstrak 100 fitur (kata) berbobot tertinggi berdasarkan frekuensi kemunculannya.
2. **Pendekatan Deep Learning (IndoBERT):** Mengekstrak 768 dimensi *embedding* (vektor semantik) dari model bahasa *indobenchmark/indobert-base-pl* dengan memanfaatkan representasi token CLS.

4.2 Implementasi A/B Testing Menggunakan Python

Dokumentasikan pelaksanaan uji eksperimen A/B Testing dengan struktur berikut:

- **Hipotesis Nol (H0):** Tidak terdapat perbedaan performa akurasi yang signifikan antara representasi TF-IDF dan representasi *embedding* IndoBERT.

- **Hipotesis Alternatif (H1):** Terdapat perbedaan performa akurasi antara TF-IDF dan *embedding* IndoBERT.
- **Metrik Evaluasi:** Akurasi Klasifikasi
- **Hasil Uji Statistik:** Evaluasi model menghasilkan akurasi sebesar **32.39% untuk TF-IDF** dan **33.80% untuk IndoBERT**. Terdapat margin keunggulan pada IndoBERT yang membuktikan kemampuannya menangkap konteks bahasa Indonesia informal dengan lebih baik. **H0 ditolak**, dan IndoBERT (atau skema ML terkait) dinobatkan sebagai basis pengembangan fitur Copilot.

BAB 5: PENGEMBANGAN DASHBOARD INTERAKTIF & DEPLOYMENT

5.1 Desain Komponen Dashboard

Dashboard Coding Camp Copilot dirancang dengan antarmuka mode gelap yang profesional dan terbagi dalam 4 tab interaktif:

- Eksplorasi Data: Menampilkan *Metric Cards*, grafik distribusi proporsi jalur (*Pie & Bar chart*), serta tabel data dengan fitur *selectbox* untuk memfilter pertanyaan berdasarkan *Path* dan kolom pencarian kata kunci.
- A/B Testing Model: Menyajikan visualisasi perbandingan akurasi algoritma dan wawasan evaluasi (*insight box*).
- Simulasi Live: Komponen interaktif utama di mana pengguna dapat mengetik pertanyaan administratif baru, lalu sistem merespons dengan *Path* prediksi beserta *progress bar* distribusi keyakinan model secara *real-time*.
- Insight & Ringkasan: Rekapitan rekomendasi strategis bagi manajemen program.

5.2 Pengembangan via Streamlit & Deployment

Dashboard dikembangkan menggunakan Python dengan integrasi pustaka Streamlit, Pandas, dan Matplotlib/Seaborn. Untuk optimasi memori komputasi, digunakan dekorator `@st.cache_data` pada fungsi pemuatan dataset dan `@st.cache_resource` pada pelatihan model *Random Forest* instan. Aplikasi ini telah dirilis ke publik secara mulus menggunakan Streamlit Community Cloud, yang menarik skrip `dashboard.py` dan konfigurasi

requirements.txt langsung dari repositori GitHub tim.

BAB 6: KESIMPULAN & REKOMENDASI BISNIS

6.1 Kesimpulan

Berdasarkan analisis data, pertanyaan bisnis telah terjawab yaitu sebagian besar volume lalu lintas forum diisi oleh isu administratif berulang dari seluruh *Path*. Pengujian model klasifikasi membuktikan bahwa penerapan kecerdasan buatan mampu secara otomatis mengenali dan merutekan kategori pertanyaan peserta secara *real-time*, di mana pendekatan *embedding* bahasa seperti IndoBERT terbukti lebih unggul dalam membedah teks percakapan peserta dibandingkan ekstraksi statistik tradisional.

6.2 Rekomendasi (Actionable Insights)

Manajemen harus merangkum *Top 10* pertanyaan yang paling sering muncul (seperti ILT, email, tenggat waktu capstone) ke dalam dokumen panduan FAQ resmi yang lebih ringkas. Tim admin dan mentor disarankan menggunakan fungsi *Live Prediction* dari dashboard untuk menyaring dan merutekan pertanyaan baru secara instan. Untuk meningkatkan akurasi model di masa depan, disarankan untuk mengumpulkan lebih banyak sampel data organik dari *batch* berikutnya serta menerapkan teknik pelabelan yang lebih merata (*oversampling*).

REFERENSI & LAMPIRAN

Pustaka Pemrograman : Python 3, Streamlit, Scikit-Learn, Pandas, Matplotlib, Sastrawi.

Model NLP Basis : *indobenchmark/indobert-base-p1* (HuggingFace).

Repositori Kode (GitHub) :

https://github.com/devilistiani/coding_camp_copilot

Aplikasi Live Dashboard : <https://codingcampcopilot.streamlit.app/>